Inteligencia de Negocios
Proyecto semestral

Avance 1 - Proyecto BI - Ecobici CDMX

Equipo: LOS CAMPECHANOS

Proyecto: Análisis de patrones de uso y comportamiento territorial del sistema Ecobici en la CDMX.

Integrantes: Carlos Josafat Fragoso Palma; Edson Joel Carrera Ávila; Francisco Javier García Rojas

Grupo: Fecha: Septiembre 2026

Fuente seleccionada: Kaggle - “Ecobici CDMX Trip Data”

Enlace al repositorio: https://github.com/CarWhite01/BI_Ecobici2026.git

Descripción: Proyecto analítico orientado a identificar patrones de uso de Ecobici y diferencias entre estaciones y zonas donde actualmente opera el sistema, considerando variables temporales, de usuario y, cuando sea posible, información territorial asociada a las estaciones.

3.1. Identificación del proyecto

Problema organizacional y decisión

La Secretaría de Movilidad de la CDMX (SEMOVI) requiere comprender cómo se distribuye el uso de Ecobici entre las estaciones y zonas donde actualmente opera el sistema. Esta información puede apoyar decisiones relacionadas con la operación y con futuras evaluaciones de infraestructura.

La propuesta se ajusta debido a que los datos disponibles deben revisarse antes de afirmar que permiten estimar la demanda en lugares donde actualmente no existe el servicio. Por ello, el análisis se concentrará inicialmente en el comportamiento observado en estaciones y zonas con cobertura.

3.2. Problema organizacional y decisión

• **Contexto:** La Secretaría de Movilidad de la CDMX (SEMOVI) gestiona el sistema Ecobici. El sistema cuenta con registros históricos de viajes que permiten estudiar su comportamiento en las zonas donde actualmente existe cobertura.

• **Situación problemática:** No se conoce con suficiente detalle cómo se concentra el uso del sistema entre estaciones y zonas, ni qué características presentan los lugares con mayores y menores niveles de utilización.

• **Actores:** La Dirección de Movilidad Sostenible de SEMOVI y los urbanistas de la ciudad.

• **Decisión esperada:** Identificar patrones de utilización y características de las estaciones y zonas con diferente nivel de uso, como información de apoyo para decisiones de operación e infraestructura.

• **Alcance:** Se estudiarán los viajes históricos registrados y se analizarán sus dimensiones temporales, de usuario y territoriales, siempre que estas últimas puedan relacionarse de forma comprobable con las estaciones. Se podrá cruzar información con INEGI cuando exista una relación territorial válida.

3.3. Pregunta de negocio

Pregunta Principal: ¿Cómo varía el uso de Ecobici entre las estaciones y zonas donde actualmente opera el sistema, y qué características demográficas y territoriales presentan los lugares con mayor y menor utilización?

Preguntas secundarias:

1. ¿Qué estaciones concentran el mayor y menor número de viajes y cómo varía su utilización según día, hora y periodo?

2. ¿Qué características demográficas de las zonas donde se encuentran las estaciones se relacionan con mayores niveles de uso?

3. ¿Existen diferencias en los patrones de uso entre las distintas zonas o alcaldías con cobertura de Ecobici?

3.4. Justificación del uso de BI

El uso de un sistema de Inteligencia de Negocios es adecuado porque el análisis requiere integrar y transformar un volumen importante de registros de viajes para obtener indicadores y comparaciones útiles para la toma de decisiones.

• **Volumen de datos:** El histórico de Ecobici supera los 100 millones de registros, lo que dificulta un análisis tradicional en hojas de cálculo.

• **Integración de fuentes:** Se requiere relacionar los datos transaccionales de viajes con información de estaciones y, si la relación es comprobable, con información territorial y censal de INEGI.

• **Reproducibilidad:** Un pipeline ETL permitirá actualizar los análisis cuando se incorporen nuevos periodos de viajes o información de estaciones.

• **Toma de decisiones:** SEMOVI puede utilizar un dashboard interactivo para observar concentración de viajes, horarios, estaciones y diferencias territoriales.

3.5. Dataset seleccionado y fuente alternativa

Se mantiene la selección de Kaggle como fuente principal, de acuerdo con la primera entrega.

Criterio	Dataset de Kaggle (Seleccionado)	Fuente alternativa
Nombre y enlace	Ecobici CDMX Trip Data (Kaggle)	Portal Datos Abiertos CDMX (SEMOVI)
Formato y tamaño	CSV agregados por año (~15 GB total)	Múltiples CSV mensuales
Cobertura y granularidad	2010 a la fecha. Un registro por viaje.	Igual, pero requiere descarga manual mensual.
Limitaciones	Puede tener un desfase de algunos meses respecto al portal oficial.	Fricción en la descarga masiva y cortes de servidor.
Decisión sobre la fuente	ACEPTAR. Centraliza años de historial listos para su uso.	Usar como fuente alternativa si Kaggle falla.

3.6. Inventario y primera lectura de los datos crudos

Inventario de archivos

• **Viajes_Ecobici.csv:** +100M registros, 9 columnas, formato CSV. Unidad de observación: un viaje individual realizado por un usuario.

• **Demografia_INEGI.csv:** 2,433 registros y 15 columnas, formato CSV. Unidad de observación: un Área Geoestadística Básica (AGEB), Censo 2020.

Variables identificadas en la primera revisión:

• **Genero_Usuario:** sexo registrado del usuario. Presenta valores “M”, “F” y “NA” o nulos.

• **Edad_Usuario:** edad al momento del viaje. Se observaron valores extremos que requieren revisión.

• **Fecha_Retiro:** día y hora de inicio del viaje. Se encuentra como texto y requiere conversión a DateTime.

Revisión pendiente y condición para el análisis territorial: Antes de utilizar alcaldías, AGEB o zonas como dimensión del viaje, se deberá comprobar en el archivo de viajes la existencia de identificadores o nombres de estación de origen y destino y/o coordenadas que permitan asociar cada estación con información territorial. No se asumirá esta relación si los datos no la contienen.

3.7. Plan analítico preliminar

Necesidad analítica	Evento y granularidad	Dimensiones	Medidas base	Métrica o KPI
Identificar estaciones con mayor y menor uso	Viaje individual	Estación, fecha, hora	Conteo de viajes	Viajes por estación; participación porcentual
Identificar patrones temporales	Viaje individual	Día, hora, periodo	Conteo de viajes	Viajes por hora y día; % en horas pico
Comparar comportamiento territorial	Estación/zona, si existe relación comprobable	Alcaldía, AGEB o zona	Viajes, población	Viajes por zona y, cuando sea válido, viajes por habitante

Necesidad analítica	Evento y granularidad	Dimensiones	Medidas base	Métrica o KPI
Analizar perfil de uso	Viaje individual	Género, rango de edad	Conteo de viajes	% de viajes por grupo

3.8. Arquitectura propuesta de la cadena BI

Se mantiene la arquitectura propuesta originalmente, ajustando el objetivo del análisis:

• **Python:** archivos CSV crudos de Kaggle e INEGI. Perfilar, limpiar valores nulos/extremos y formatear fechas. Verificar específicamente las variables de estación de origen y destino.

• **ETL:** datos limpios. Automatizar la carga de los datos al almacén de bases de datos.

• **PostgreSQL:** almacenar bajo un modelo dimensional (Estrella), integrando viajes, estaciones y, cuando sea posible, información demográfica.

• **Power BI:** construir un dashboard interactivo para visualizar estaciones, patrones temporales y diferencias territoriales.

3.9. Riesgos, límites y dudas abiertas

Riesgo o duda	Evidencia disponible	Efecto posible	Cómo y cuándo se atenderá
Datos atípicos en edades	Registros con edades > 100 años.	Distorsión del perfil de usuario promedio.	Filtrar en Python durante la limpieza.
Relación de viajes con estaciones	La primera revisión documenta variables de usuario y tiempo, pero aún no demuestra las variables de estación.	No sería posible realizar un análisis territorial por estación si no existe una clave de relación.	Verificar las 9 columnas del archivo de viajes antes de cerrar el modelo analítico.
Relación con AGEB/alcaldía	INEGI contiene información por AGEB, pero debe existir una correspondencia territorial con las estaciones.	No se podrá atribuir demografía a una estación sin una relación espacial comprobable.	Construir la relación únicamente si existen identificadores o coordenadas suficientes.
Desactualización de INEGI	Datos demográficos del 2020.	La demografía posterior a la pandemia pudo variar.	Se asumirá el Censo 2020 como referencia y se indicará como limitación.
Estimación de demanda en zonas sin servicio	Los viajes observados corresponden a estaciones existentes.	No permite observar directamente la demanda de una estación inexistente.	Se excluye de la pregunta principal; cualquier análisis futuro de expansión requerirá fuentes adicionales y supuestos explícitos.

3.10. Conclusión de viabilidad y siguientes pasos

El proyecto es viable con un ajuste en la pregunta de negocio. Los datos identificados permiten analizar viajes históricos y construir indicadores sobre el comportamiento temporal y el perfil de los usuarios. Sin embargo, antes de afirmar que es posible realizar un análisis territorial detallado, se debe comprobar que los viajes pueden relacionarse con estaciones de origen y destino y que dichas estaciones pueden asociarse de manera válida con información territorial.

Lo que se puede concluir: Se pueden identificar patrones de uso, horarios de mayor actividad, diferencias entre estaciones y, si existe una relación territorial comprobable, características de las zonas donde se encuentran las estaciones.

Lo que NO se puede concluir con los datos actualmente documentados: No se puede estimar directamente la demanda de estaciones o zonas donde actualmente no existe el servicio, ni establecer por sí solo un ranking de alcaldías para expansión. Tampoco se evaluarán presupuestos financieros ni viabilidad topográfica.

Siguientes pasos: Durante las siguientes semanas, el equipo verificará la estructura completa del archivo de viajes, especialmente las variables de estación de origen y destino. Posteriormente realizará la limpieza de fechas y edades, establecerá las relaciones territoriales que los datos permitan y preparará el modelo en PostgreSQL para su análisis en Power BI.