Avance 2: lectura, perfilamiento y preparación de datos con Python

Proyecto: Patrones de uso y comportamiento territorial de Ecobici CDMX

Equipo LOS CAMPECHANOS: Carlos Josafat Fragoso Palma, Edson Joel Carrera Ávila, Francisco Javier García Rojas

Inteligencia de Negocios · Semestre 2026-2 · UACM · Octubre de 2026

> *Evidencia y código: notebook `advance 2 ecobici.ipynb` (carpeta `notebooks/`). Las tablas de evidencia están en `salidas/`. Los textos entre corchetes **[COMPLETAR]** deben llenarse con información que solo el equipo conoce.*

1. Planeamiento vigente y continuidad con el avance 1

Pregunta de negocio. ¿Cómo varía el uso de Ecobici entre las estaciones y zonas donde opera el sistema, y qué características territoriales, presentan los lugares con mayor y menor utilización?

Usuarios de la información y decisión. La Dirección de Movilidad Sostenible de SEMOVI y urbanistas de la ciudad, como apoyo a decisiones de operación e infraestructura.

Variables indispensables. Estación de retiro y de arribo, fecha y hora de retiro y de arribo, bicicleta, género y edad del usuario.

1.1 Ajustes respecto al avance 1

Aspecto	Avance 1	Avance 2	Motivo
Fuente de viajes	Kaggle, con tres CSV (`Ecobici.csv`, `Viajes.csv`, `Usuarios.csv`). Las variables listadas no incluían estación de origen ni de destino	CSV mensual del portal oficial de datos abiertos de Ecobici (`public_data_web_2026-09.csv`) , con un registro por viaje y estación de retiro y de arribo	Con estaciones sí se pueden responder las preguntas por estación, ruta y tiempo. La fuente oficial también resuelve la duda de procedencia de Kaggle
Alcance temporal	2010 a la fecha	Un mes: septiembre de 2026	Alcance de este avance
Catálogo de estaciones	No contemplado	Snapshot del feed GBFS de Ecobici (22-abr-2024), tomado del repositorio público `SimonHFrost/ecobici-api-poll-and-save`	El CSV solo trae códigos de estación; sin catálogo no hay ubicación

Aspecto	Avance 1	Avance 2	Motivo
Demografía y entorno	Censo 2020 de INEGI	Fuentes planeadas (Censo 2020 por AGEB y DENUE), aún no leídas	Quedan para la etapa de integración

1.2 Retroalimentación del avance 1

Observación recibida	Acción realizada	Evidencia
Modificamos la pregunta número 2	**Cambiamos la pregunta a** ¿Qué rutas tienen mayor y menor afluencia?	**sección de preguntas secundarias**

1.3 Qué parte de la pregunta puede responderse

- **Sí (potencialmente):** estaciones con más y menos viajes, variación por día y hora, rutas origen-destino y perfil por género y edad.
- **Condicionada:** diferencias por alcaldía o zona (requiere coordenadas y un cruce espacial posterior) y demografía (requiere el Censo 2020 por AGEB).
- **No:** estimar demanda donde no hay servicio, descartado desde el avance 1.

2. Lectura de los datos y contrato de lectura (nota 06)

Campo	Viajes	Catálogo de estaciones
Fuente	Portal de datos abiertos de Ecobici, sección *Descarga de información histórica*	Feed GBFS `station_information` de Ecobici, vía snapshots del repositorio `SimonHFrost/ecobici-api-poll-and-save`
Versión o fecha	Archivo del mes 2026-09; descargado el **10/10/26 y 20/10/2026**	Snapshot `20240422210451`, el más reciente de los 399 archivos del repositorio
Recurso	`datos_crudos/public_data_web_2026-09.csv`	`datos_crudos/station_information_20240422210451.json`, lista `data.stations`
Función y parámetros	`pd.read_csv(sep=",", encoding="utf-8", header=0)`; `Bici` y los dos códigos de estación se leen	`json.load()` y `pd.json_normalize(datos["data"]["stations"])`

Campo	Viajes	Catálogo de estaciones
	como texto para conservar ceros a la izquierda (`028`)	
Objeto esperado	DataFrame de 9 columnas	DataFrame con una fila por estación
Resultado	1,498,934 filas y 9 columnas	667 filas y 12 columnas
Control de correspondencia	Las 1,498,934 fechas de arribo caen en 09/2026, igual que el mes del archivo. Los nombres de columnas coinciden con los esperados	Los códigos del CSV se comparan con `short_name` en la sección 4
Advertencias	Lectura completa, sin `nrows` ni `chunksize`. La página no declara un conteo oficial de filas, por lo que ese control queda pendiente	Es un snapshot de 2024 de un repositorio de terceros, no el feed oficial actual. Un archivo del repositorio (`station_information_20240412140435.json`) está corrupto y no se usa

La lectura sin errores solo demuestra que se abrió el recurso previsto; no demuestra que los datos estén completos ni limpios. Evidencia: notebook, sección 1.

3. Perfil inicial (nota 07)

El perfil se construyó **antes** de modificar cualquier valor. Cada fila representa un viaje. Como llave candidata se propuso `Bici + Fecha_Retiro + Hora_Retiro` (una bicicleta no puede iniciar dos viajes en el mismo segundo) y se comprobó con `duplicated()`.

3.1 Perfil por columna

Columna	Tipo detectado	Valores nulos	Valores distintos
`Genero_Usuario`	texto	0	4
`Edad_Usuario`	float64	29 (0.0019 %)	73
`Bici`	texto	0	6,574
`Ciclo_Estacion_Retiro`	texto	0	676
`Fecha_Retiro`	texto	0	38
`Hora_Retiro`	texto	0	69,839
`Ciclo_EstacionArribo`	texto	0	676

Columna	Tipo detectado	Valores nulos	Valores distintos
`Fecha_Arribo`	texto	0	30
`Hora_Arribo`	texto	0	71,072

`Edad_Usuario` aparece como `float64` solo por sus ausencias: no hay edades con decimales. Un tipo detectado no demuestra que corresponda al significado de la columna.

3.2 Frecuencias y extremos

- **Género:** M 1,016,851; F 416,346; `?` 38,763; O 26,974.
- **Edad:** mínimo 16, mediana 33, media 34.8, máximo 98. Hay 14 registros de 97 o 98 años. Los 29 registros sin edad se reparten en 18 de género M y 11 de género F.
- **Duración de los viajes** (calculada aparte, sin modificar la tabla): mediana de 11.8 minutos, sin duraciones negativas, 215 viajes de menos de 1 minuto, 538 de más de 3 horas y 31 de más de 24 horas (el máximo supera los 300,000 minutos).
- **Estaciones:** 676 códigos distintos, 12 de ellos compuestos (por ejemplo `271-272`, el código con más retiros: 11,270). Hay 41,245 viajes (2.8 %) con origen igual a destino.
- **Duplicados:** 0 filas idénticas y 0 repeticiones de la llave candidata.

4. Hallazgos

Id	Señal	Evidencia	Posible efecto analítico	Aclaración pendiente
H1	Edad ausente	29 de 1,498,934 filas	Sesgar el perfil por edad si se imputa o excluye sin criterio	Significado de la ausencia en la fuente
H2	Género `?` y `O`	`?`: 38,763; `O`: 26,974	Subestimar M y F si se mezclan o eliminan	Catálogo de la fuente que defina ambos valores
H3	Edades muy altas	Máximo 98; 14 registros con 90 o más	Poco efecto en promedios; relevante si se segmenta por edad	Rango de edad admisible
H4	Retiros anteriores a septiembre	101 filas (98 de agosto, 3 de febrero, mayo y junio); todos con arribo en septiembre	Asignar un viaje al mes equivocado	Si el corte del archivo es por fecha de arribo
H5	Duraciones extremas	215 menores a 1 min; 538 mayores a 3 h; 31 mayores a 24 h	Distorsionar promedios de duración	Límite de duración del servicio y causa de los casos largos

Id	Señal	Evidencia	Posible efecto analítico	Aclaración pendiente
H6	Origen igual a destino	41,245 viajes (2.8 %)	Confundir rutas circulares con rutas reales	Si son viajes cortos válidos o retiros cancelados
H7	Códigos de estación compuestos	12 códigos (por ejemplo `107-108`, `271-272`)	Contar como una estación lo que pueden ser dos	Significado del código compuesto
H8	Estaciones sin catálogo	12 códigos (511, 524, 529, 530, 675, 676, 677, 680, 681, 682, 710, 711); 30,454 viajes (2.03 %)	Sin coordenadas no hay análisis territorial de esos viajes	Catálogo vigente (el snapshot es de abril de 2024)
H9	Repeticiones	Exactas: 0; llave candidata repetida: 0	Inflar el conteo de viajes	Sin pendientes por ahora

Comprobaciones adicionales del catálogo: sin nulos, sin `short_name` duplicados, 2 estaciones con coordenadas 0,0 (`Sup002` y `1123`, que no aparecen en los viajes) y 3 estaciones del catálogo que no aparecen en los viajes. Evidencia: notebook, secciones 2.3 a 2.10; `salidas/hallazgos_perfil.csv`.

5. Reglas de preparación y su aplicación (nota 08)

Cada tratamiento siguió la fórmula de la nota 08: *modificaré… porque la regla indica… y comprobaré el resultado mediante…*. Se trabajó sobre una copia (`limpio`) y `viajes_crudos` quedó intacto.

Regla	Hallazgo	Qué se hizo	Fundamento	Comprobación y resultado
R1	H1, H3	`Edad_Usuario` pasó de `float64` a `Int64` con `to_numeric` y `astype`; **no se imputó**	La edad es un entero de años; una ausencia significa dato no disponible	0 fallos de conversión, 0 decimales, 29 nulos antes y 29 después
R2	H2	Se aplicó `strip` y mayúsculas al género; no se mapearon `?` ni `0`	Formato superficial sin cambio de significado; no existe catálogo que defina `?` ni `0`	0 valores modificados, 4 categorías antes y después, filas iguales
R3	H4, H5	Se agregaron `fecha_hora_retiro` y `fecha_hora_arribo` (`datetime`) con el formato `%d/%m/%Y`	La fuente declara ese formato; declararlo evita la ambigüedad entre día y mes	0 fallos de conversión; arribos entre 2026-09-01 y 2026-09-30

Regla	Hallazgo	Qué se hizo	Fundamento	Comprobación y resultado
		`%H:%M:%S`; se conservaron las columnas originales		
R4	H4	Bandera `retiro_fuera_periodo`	El archivo corresponde a septiembre; un retiro anterior se marca, no se elimina ni se corrige	101 banderas; filas conservadas
R5	H8	Banderas `retiro_sin_catalogo` y `arribo_sin_catalogo` con `isin()`	El catálogo es la única referencia documentada; un código sin equivalencia no se asigna a otra estación	12 códigos sin equivalencia, 30,454 viajes marcados; filas conservadas
R6	H7	Sin cambios	`271-272` y demás códigos compuestos existen tal cual en el catálogo	Los 12 compuestos pertenecen al catálogo
R7	H9	`drop_duplicates()` solo sobre filas idénticas	Una fila idéntica no aporta un viaje; una repetición de la llave con valores distintos sería un conflicto	0 duplicados exactos, 0 llaves repetidas; filas antes y después: 1,498,934
R8	H5, H6	Sin cambios	No hay una regla documentada del servicio que autorice corregir o excluir duraciones largas ni viajes con origen igual a destino	Se reportan como pendientes en la validación

Tratamientos que no corresponden a este dataset: conversión de unidades (no hay magnitudes en unidades mezcladas), homologación de categorías con diccionario (no hay equivalencias que documentar) y relleno de faltantes.

Evidencia: notebook, secciones 3 y 4; `salidas/bitacora_transformaciones.csv`.

6. Comparación antes y después

Métrica	Antes	Después
Filas	1,498,934	1,498,934
Columnas	9	14 (5 nuevas: dos de fecha-hora y tres banderas)
Nulos en `Edad_Usuario`	29	29

Métrica	Antes	Después
Tipo de `Edad_Usuario`	float64	Int64
Categorías distintas de género	4	4
Duplicados exactos	0	0
Filas con llave candidata repetida	0	0
Tipo de fecha y hora de retiro	texto (fecha y hora separadas)	datetime
Retiros fuera del periodo	no identificados	101 marcados
Viajes con estación sin catálogo	no identificados	30,454 marcados

Ausencias originales frente a fallos de conversión. Las 29 ausencias de edad son originales (0 fallos de conversión). La conversión de fechas y horas tuvo 0 fallos en retiro y en arribo, y no había ausencias originales en esas columnas. Los 12 códigos de estación sin equivalencia no son ausencias: son valores presentes que el catálogo no reconoce.

Evidencia: notebook, sección 6; `salidas/comparacion_antes_despues.csv`.

7. Validación de los datos preparados

Cada validación expresa el uso al que se aplica, la condición esperada y la acción prevista si falla. Una validación fallida no se resolvió eliminando filas.

Validación	Uso	Condición esperada	Resultado	Acción si falla
Campos obligatorios	Cualquier análisis	Bici, estaciones y fechas presentes	Cumple	Excluir solo con regla documentada
Llave única	Conteo de viajes	`Bici + fecha_hora_retiro` sin repetir	Cumple	Investigar el conflicto con la fuente
Fechas convertidas	Análisis temporal	Sin NaT nuevos	Cumple	Revisar el registro original
Arribo no anterior a retiro	Duración de viajes	Arribo ≥ retiro	Cumple	Marcar y consultar la fuente
Retiro dentro del periodo	Análisis por mes de retiro	Retiro en septiembre de 2026	**Pendiente** (101 casos)	Usar mes de arribo o excluir con criterio acotado
Arribo dentro del periodo	Análisis por mes	Arribo en septiembre de 2026	Cumple	Revisar el corte del archivo

Validación	Uso	Condición esperada	Resultado	Acción si falla
Retiro en catálogo	Análisis territorial por estación	Código existe en el catálogo	**Pendiente** (17,752 viajes)	Conseguir catálogo vigente
Arribo en catálogo	Análisis territorial y rutas	Código existe en el catálogo	**Pendiente** (15,435 viajes)	Conseguir catálogo vigente
Género en conjunto provisional	Perfil de usuario	Valor en {M, F, O, ?}, conjunto observado sin catálogo oficial	Cumple	Consultar el catálogo de la fuente
Edad entera anulable	Perfil por edad	Tipo `Int64`	Cumple	Revisar la conversión
Bici de 7 dígitos	Identificar bicicletas	7 dígitos numéricos	Cumple	Revisar el identificador
Coordenadas válidas en estaciones usadas	Mapas y cruces espaciales	Latitud y longitud distintas de 0	Cumple	Excluir esas estaciones de los mapas
Filas conservadas	Trazabilidad	Filas = crudas − duplicados exactos	Cumple	Revisar reglas de exclusión

Resultado: 10 de 13 condiciones se cumplen y 3 quedan pendientes. Los 17,752 retiros y 15,435 arribos sin catálogo suman 30,454 viajes distintos con al menos uno de los dos extremos sin ubicación. Evidencia: notebook, sección 5; `salidas/validaciones.csv`.

Casos informativos (no son errores demostrados): 215 duraciones menores a 1 minuto, 538 mayores a 3 horas, 31 mayores a 24 horas, 41,245 viajes con origen igual a destino, 14 registros con 90 años o más y 38,763 viajes con género `?`.

8. Conclusiones: qué datos pueden usarse y qué limitaciones permanecen

8.1 Usos posibles

Los 1,498,934 viajes de septiembre de 2026 se leyeron completos, sin duplicados exactos, con fechas interpretativas y con una llave de viaje única. Con esa base pueden respaldarse:

- Viajes por estación (retiro y arribo) y rutas origen-destino.
- Patrones por día y hora, con `fecha_hora_retiro`.
- Perfil por género y edad, con las salvedades indicadas.
- Análisis territorial por estación para los viajes cuyas estaciones están en el catálogo: 664 de 676 códigos, que equivalen al 97.97 % de los viajes.

8.2 Limitaciones que permanecen

Tema	Evidencia	Qué análisis limita
Estaciones sin catálogo	12 códigos; 30,454 viajes (2.03 %)	Mapas y cruces espaciales de esos viajes; el catálogo es un snapshot de 2024 de un repositorio de terceros
Periodo	101 retiros anteriores a septiembre	Conteos por mes de retiro
Duraciones	215 menores a 1 min, 538 mayores a 3 h, 31 mayores a 24 h	Promedios de duración; falta una regla del servicio
Origen igual a destino	41,245 viajes (2.8 %)	Rutas: pueden ser viajes cortos válidos o retiros cancelados
Códigos compuestos	12 códigos (`271-272` con 11,270 retiros)	Conteo por estación: se tratan como una unidad hasta aclarar su significado
Género	`?` en 38,763 viajes (2.6 %) y `0` en 26,974, sin catálogo	Perfil por género
Edad	29 ausentes; 14 registros de 97 o 98 años; rango sin documentar	Perfil por edad
Alcance	Un solo mes; INEGI aún no se lee	Estacionalidad, tendencias anuales y todo lo demográfico

8.3 Pendientes para consultar o resolver

1. Obtener el catálogo de estaciones vigente (feed GBFS actual) y aclarar el significado de los códigos compuestos.
2. Conocer la definición de `?` y `0` en género y el rango de edad admisible.
3. Confirmar si el corte mensual del archivo es por fecha de arribo y si la fuente publica un conteo de filas.
4. Definir una regla de duración máxima del servicio para tratar los viajes extremos.
5. Leer el Censo 2020 por AGEB y el DENUE para el cruce espacial en la siguiente etapa.

Los datos preparados sirven para los usos listados bajo las condiciones indicadas; **no** están listos para cualquier decisión.

9. Reproducibilidad y trabajo en equipo

- **Código:** `notebooks/avance2_ecobici.ipynb`. Se ejecuta de principio a fin con *Restart & Run All*, sin pasos manuales ocultos. Las rutas se calculan con `pathlib`.
- **Dependencias:** Python 3.10 o superior, `pandas` (probado con 3.0) y `jupyter` (`requirements.txt`).
- **Datos crudos:** el CSV pesa cerca de 96 MB y se obtiene del portal de datos abiertos de Ecobici (2026, mes 2026-09); el catálogo está en `datos_crudos/` y proviene del repositorio indicado en la sección 2. Instrucciones en `README.md`.
- **Resultado preparado:** el DataFrame `limpio` del notebook, que se regenera al ejecutarlo.
- **Bitácora del equipo:** `docs/bitacora_equipo.md` (tarea, responsable principal, evidencia y estado). **[COMPLETAR responsables y acciones derivadas de la retroalimentación]**
- **Verificación de reproducibilidad: Carlos Josafat Fragoso ejecutó el notebook desde cero y en google colab**